Università degli Studi di Bari 'Aldo Moro'
Dipartimento di Matematica
Corso di Laurea Triennale in Matematica

Tecniche probabilistiche per il riconoscimento di argomenti latenti: il modello PLSA

Relatore
Prof.ssa Nicoletta Del Buono

Laureando
Angelo Gabriele Lapacciana

Introduzione alla LSA

La *Latent Semantic Analysis* (LSA) è una tecnica che, a partire dalla matrice termine–documento, utilizza la **decomposizione ai valori singolari** (SVD) per ridurre la dimensionalità dei dati. Così costruisce uno **spazio semantico latente** in cui documenti e termini sono rappresentati da vettori compatti. Questo consente di catturare relazioni nascoste e di migliorare il recupero delle informazioni anche in presenza di **sinonimia** e **polisemia**.

Matrice termine-documento

	Documento 1	Documento 2	Documento 3
Termine 1	0	0	0
Termine 2	0	0	1
Termine 3	0	0	0
Termine 4	0	0	2
Termine 5	0	4	0
Termine 6	0	0	0
Termine 7	2	0	0

Una collezione di testi può essere rappresentata tramite una matrice **termine–documento**: ogni riga corrisponde a un termine del vocabolario e ogni colonna a un documento. Questa rappresentazione, nota come modello *Bag-of-Words*, è semplice ma presenta limiti:

la matrice è **estremamente sparsa** (meno dell'1% dei valori è diverso da zero) e non coglie fenomeni linguistici come **sinonimia** e **polisemia**. Per questo, due testi semanticamente simili possono sembrare diversi, o apparire simili solo perché condividono parole ambigue.

Riduzione con la SVD

La LSA riduce la dimensionalità della matrice termine–documento, proiettando documenti e termini in uno **spazio semantico latente** dove emergono relazioni nascoste. La riduzione avviene grazie alla **SVD**, che scompone la matrice e la approssima con le componenti principali. In questo spazio, documenti semanticamente affini risultano vicini anche senza termini in comune, superando parzialmente i limiti del modello Bag-of-Words.

$$A = U \Sigma V^T$$

Introduzione alla PLSA

La *Probabilistic Latent Semantic Analysis* (PLSA) è un modello statistico che descrive le co-occorrenze parola–documento in termini **probabilistici**. L'obiettivo è superare i limiti della LSA classica, che si fonda solo su strumenti algebrici, introducendo un approccio basato sulla **verosimiglianza**.

La PLSA permette di rappresentare ogni documento come una **combinazione di argomenti latenti** e consente di gestire meglio fenomeni linguistici come **sinonimia** e **polisemia**, migliorando il recupero e il filtraggio delle informazioni.

Aspect Model

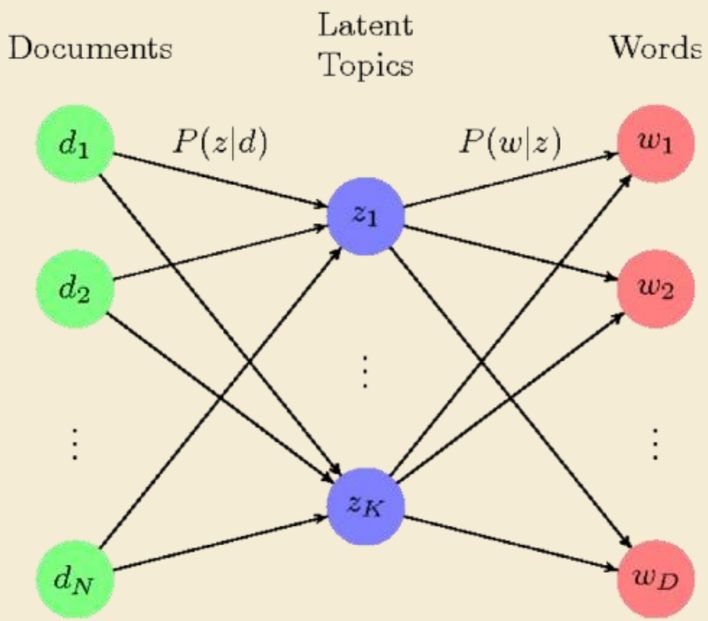

La PLSA si fonda sull'**Aspect Model**, un modello a variabili latenti che descrive la generazione delle coppie (documento, parola). L'idea è che ogni parola osservata in un documento sia prodotta scegliendo prima un documento, poi un argomento latente e infine una parola coerente con quell'argomento.

Formalmente, la probabilità congiunta di osservare una coppia (d, w) è data da:

$$P(d,w) = P(d) \sum_z P(z|d)P(w|z)$$

dove gli argomenti latenti *z* fungono da ponte tra documenti e parole, rendendo esplicita la struttura semantica nascosta.

Addestramento con l'algoritmo EM

Expectation

Si calcolano le probabilità a posteriori delle variabili latenti, cioè la probabilità che una certa parola in un documento sia stata generata da un determinato argomento.

Maximization

Si aggiornano i parametri del modello, ovvero le distribuzioni delle parole dato l'argomento e degli argomenti dato il documento, in modo da massimizzare la verosimiglianza.

Geometria e Spazio Semantico

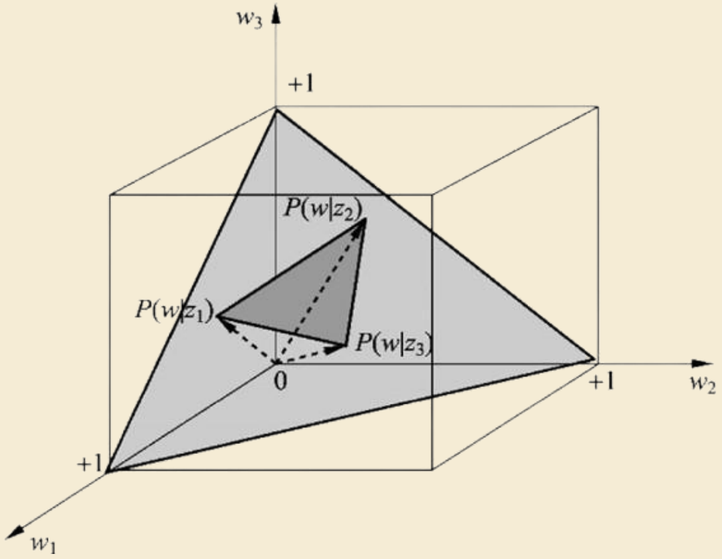

Dal punto di vista geometrico, ogni argomento latente può essere interpretato come un punto in un **simplesso di probabilità**. I documenti risultano quindi rappresentabili come **combinazioni convesse** degli argomenti, collocandosi all'interno del simplesso. In questo modo si ottiene uno **spazio semantico latente probabilistico**, che riduce drasticamente la dimensionalità del problema: dallo spazio originario, legato alla dimensione del vocabolario, a uno spazio con pochi fattori latenti.

Confronto tra LSA e PLSA

LSA

- Basata su **algebra lineare**
- Riduce la matrice con **SVD** : $A = U \Sigma V^T$
- Costruisce uno **spazio semantico latente** compatto
- Gestione di **sinonimia** e **polisemia** solo parziale

PLSA

- Basata su **modello generativo probabilistico**
- **Probabilità congiunta** : $P = \hat{U} \hat{\Sigma} \hat{V}^T$
- Documento = **miscela di argomenti latenti**
- Migliore gestione di **polisemia** e **sinonimia**

Confronto applicativo LSA vs PLSA

ANALISI

- **Obiettivo:** valutare le prestazioni predittive dei modelli su dataset test standard.
- **Problema con LSA:** valori negativi nella decomposizione rendono difficile calcolare probabilità; possibile overfitting ad alte dimensioni latenti.
- **PLSA:** approccio probabilistico → massimizza capacità predittiva e interpretabilità dei fattori latenti; gestione più robusta della sinonimia e polisemia.

RISULTATI

- Dataset **MED**: PLSA riduce la perplexity di ~3.3×, LSA ~1.9×
- Dataset **LOB**: PLSA ~2.41×, LSA ~2.08×
- PLSA migliora l'**average precision** nelle query rispetto a LSA (fino al +50% in alcune collezioni).
- PLSA consente **combinazioni di modelli** statisticamente coerenti (PLSI*, PLSI-U*, PLSI-Q*), aumentando robustezza e riducendo rumore.

PLSA per l’analisi delle immagini

La PLSA è stata adattata alle immagini sostituendo le parole con “parole visive”, ottenute da patch locali descritte con SIFT e raggruppate in un dizionario tramite k-means. Ogni immagine è così rappresentata come un Bag-of-Visual-Words. Questo approccio consente di categorizzare oggetti, classificare nuove immagini, segmentare le aree rilevanti e persino auto-annotare le immagini combinando informazioni visive e testuali.

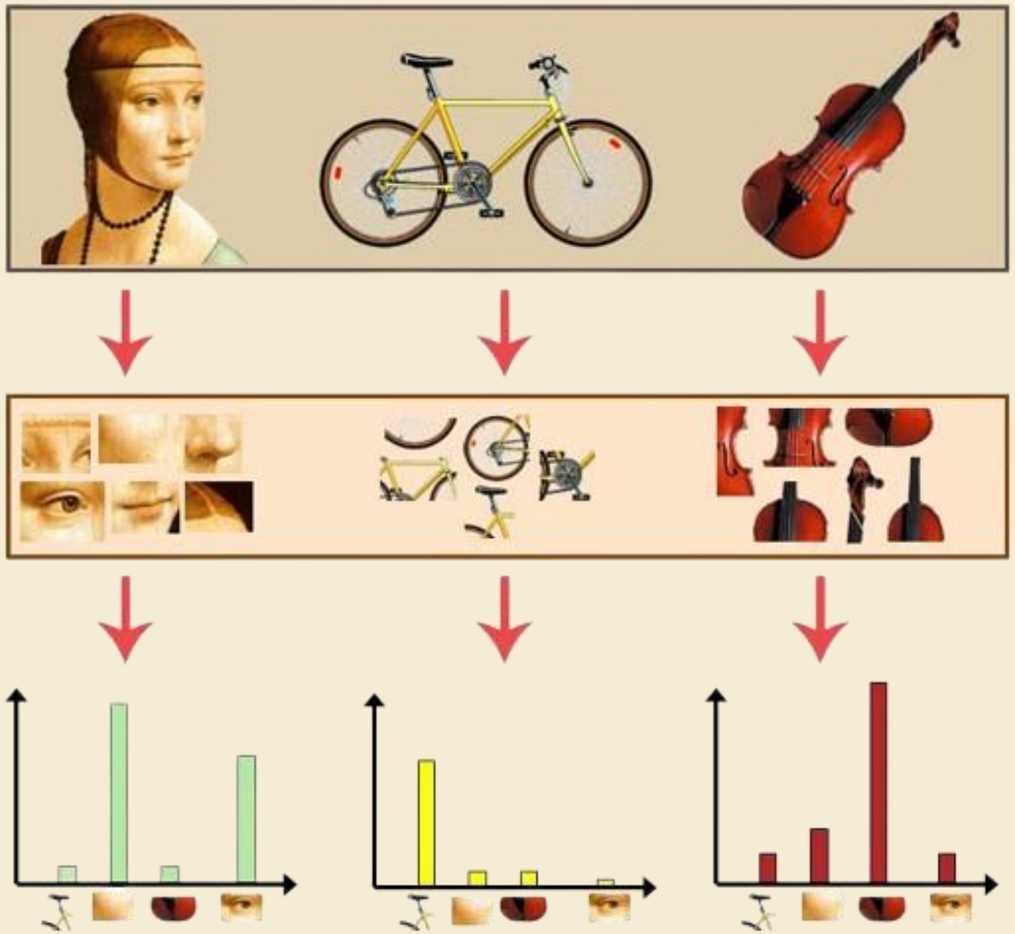

Grazie per l'attenzione

Presentato da: Angelo Gabriele Lapacciana